

Statystyka Matematyczna - Sprawozdanie 3

Bartosz Michalak

26 stycznia 2026

Wstęp

Poniższe sprawozdanie zawiera rozwiązania zadań dotyczących czynnika Bayesa, algorytmu Metropolisa-Hastingsa oraz estymacji przedziałów wiarygodnych najwyższej gęstości (HPD).

1 Czynn timer Bayesa w modelu dwumianowym

Rozważamy zmienną losową $X \sim \mathcal{B}(n, \vartheta)$ oraz problem testowania hipotez:

$$H_0 : \vartheta \leq \vartheta_0 \quad \text{vs} \quad H_1 : \vartheta > \vartheta_0$$

z rozkładem a priori $\vartheta \sim \mathcal{Be}(\alpha, \beta)$.

```
# Funkcja obliczająca B10 i interpretację
analyze_bayes_factor <- function(x, n, theta0, alpha, beta) {
  p_h0_prior <- pbeta(theta0, shape1 = alpha, shape2 = beta)
  p_h1_prior <- 1 - p_h0_prior

  alpha_post <- alpha + x
  beta_post <- beta + n - x
  p_h0_post <- pbeta(theta0, shape1 = alpha_post, shape2 = beta_post)
  p_h1_post <- 1 - p_h0_post

  prior_odds <- p_h1_prior / p_h0_prior
  post_odds <- p_h1_post / p_h0_post

  # Zabezpieczenie przed dzieleniem przez zero
  if(prior_odds == 0) return(list(B10 = 0, Evidence = "Not worth mention"))

  B10 <- post_odds / prior_odds

  evidence <- ifelse(B10 > 150, "Very strong",
                    ifelse(B10 > 20, "Strong",
                          ifelse(B10 > 3, "Positive",
                                "Not worth mention")))

  return(list(B10 = B10, Evidence = evidence))
}
```

Poniżej przedstawiono wyniki symulacji dla $n = 100$, $\vartheta_0 = 1/2$ i $M = 1000$ powtórzeń.

```

set.seed(123)
n <- 100
theta0 <- 0.5
M <- 1000
thetas <- c(0.25, 0.50, 0.75)

# Lista parametrów a priori (Alpha, Beta)
priors <- list(
  c(1,1),
  c(0.5, 0.5),
  c(2, 5),
  c(5, 2)
)

prior_names <- c("Uniform (1, 1)", "Jeffreys", "Beta(2, 5)", "Beta(5, 2)")

# Pętla po rozkładach a priori
for (i in 1:length(priors)) {
  a <- priors[[i]][1]
  b <- priors[[i]][2]
  p_name <- prior_names[i]

  results_matrix <- matrix(0, nrow=3, ncol=3)
  colnames(results_matrix) <- c("Theta = 1/4", "Theta = 1/2", "Theta = 3/4")
  rownames(results_matrix) <- c("Positive", "Strong", "Very Strong")

  # Pętla po prawdziwych wartościach theta
  for (j in 1:length(thetas)) {
    th <- thetas[j]
    X_sim <- rbinom(M, size = n, prob = th)

    # Obliczamy B10 dla całej próby
    res <- sapply(
      X_sim,
      function(x) analyze_bayes_factor(x, n, theta0, a, b)$B10
    )

    results_matrix[1, j] <- mean(res > 3 & res <= 20) # Positive
    results_matrix[2, j] <- mean(res > 20 & res <= 150) # Strong
    results_matrix[3, j] <- mean(res > 150) # Very Strong
  }

  cat("\\begin{table}[H]\\n")
  cat("\\centering\\n")

  cat(paste0(
    "\\caption{Oszacowane prawdopodobieństwa dla rozkładu a priori: ",
    p_name,
    "}\\n")
  )
}

```

```

print(knitr::kable(
  results_matrix,
  digits = 3,
  format = "latex",
  booktabs = TRUE)
)

cat("\\end{table}\\n")
cat("\\n")
}

```

Tabela 1: Oszacowane prawdopodobieństwa dla rozkładu a priori: Uniform (1, 1)

| | Theta = 1/4 | Theta = 1/2 | Theta = 3/4 |
|-------------|-------------|-------------|-------------|
| Positive | 0 | 0.209 | 0.001 |
| Strong | 0 | 0.037 | 0.002 |
| Very Strong | 0 | 0.003 | 0.997 |

Tabela 2: Oszacowane prawdopodobieństwa dla rozkładu a priori: Jeffreys

| | Theta = 1/4 | Theta = 1/2 | Theta = 3/4 |
|-------------|-------------|-------------|-------------|
| Positive | 0 | 0.191 | 0.000 |
| Strong | 0 | 0.033 | 0.005 |
| Very Strong | 0 | 0.004 | 0.995 |

Tabela 3: Oszacowane prawdopodobieństwa dla rozkładu a priori: Beta(2, 5)

| | Theta = 1/4 | Theta = 1/2 | Theta = 3/4 |
|-------------|-------------|-------------|-------------|
| Positive | 0 | 0.434 | 0 |
| Strong | 0 | 0.161 | 0 |
| Very Strong | 0 | 0.022 | 1 |

Tabela 4: Oszacowane prawdopodobieństwa dla rozkładu a priori: Beta(5, 2)

| | Theta = 1/4 | Theta = 1/2 | Theta = 3/4 |
|-------------|-------------|-------------|-------------|
| Positive | 0 | 0.049 | 0.001 |
| Strong | 0 | 0.008 | 0.011 |
| Very Strong | 0 | 0.000 | 0.988 |

Wnioski: Tabele przedstawiają prawdopodobieństwo uzyskania określonej siły dowodu przeciwko H_0 . Dla $\vartheta = 1/4$ (gdy H_0 jest prawdziwa) wiersze "Strong" i "Very Strong" zawierają wartości bliskie 0, co jest pożądane (brak błędu I rodzaju). Dla $\vartheta = 3/4$ (gdy H_1 jest prawdziwa) dominuje kategoria "Very Strong", co świadczy o wysokiej mocy testu.

2 Algorytm Metropolisa-Hastingsa dla rozkładu Weibulla

W tym zadaniu generujemy próbę X_1, \dots, X_n z rozkładu Weibulla $\mathcal{W}(\vartheta, 1)$ z gęstością:

$$p_{\vartheta}(x) = \vartheta x^{\vartheta-1} \exp(-x^{\vartheta}) \mathbf{1}_{(0,\infty)}(x)$$

Przyjmujemy rozkład a priori $\vartheta \sim \mathcal{U}(0, 1)$.

Algorytm Metropolisa-Hastingsa (Random Walk) posłuży do estymacji $E[\vartheta|x]$ oraz $\text{Median}(\vartheta|x)$.

```
set.seed(4321)

# Dwie wartości prawdziwego parametru theta
thetas_to_test <- c(0.4, 0.8)
n <- 100

log_posteriori_weibull <- function(theta, x) {
  if (theta <= 0 || theta >= 1) return(-Inf)
  n <- length(x)
  val <- n * log(theta) + (theta - 1) * sum(log(x)) - sum(x^theta)
  return(val)
}

run_mh <- function(iter, x_data, start_val=0.5, sd_prop=0.05) {
  chain <- numeric(iter)
  chain[1] <- start_val
  for(i in 2:iter) {
    curr <- chain[i-1]
    prop <- rnorm(1, curr, sd_prop)
    log_alpha <- log_posteriori_weibull(prop, x_data) -
      log_posteriori_weibull(curr, x_data)
    if (log(runif(1)) < log_alpha) chain[i] <- prop else chain[i] <- curr
  }
  return(chain)
}

# Miejsce na wyniki
estimates <- data.frame()
chains_for_plots <- list()
longest_chain_task3 <- NULL # Zmienna dla Zadania 3

# Pętla po dwóch wartościach Theta (0.4 i 0.8)
for (th_true in thetas_to_test) {

  # Generujemy dane dla aktualnego theta
  X_weibull <- rweibull(n, shape = th_true, scale = 1)

  lengths <- c(1000, 10000, 100000)

  for (L in lengths) {
    # Uruchomienie algorytmu
    ch <- run_mh(L, X_weibull)
```

```

# Zapisujemy łańcuchy do wykresów (tylko 1k i 10k)
if (L %in% c(1000, 10000)) {
  chains_for_plots[[paste(th_true, L, sep="_")] <- ch
}

# Zapamiętujemy najdłuższy łańcuch dla pierwszego przypadku (theta=0.4)
# do Zadania 3
if (L == 100000 && th_true == thetas_to_test[1]) {
  longest_chain_task3 <- ch
}

# Statystyki do tabeli
burn_in <- floor(L * 0.1)
ch_clean <- ch[-(1:burn_in)]

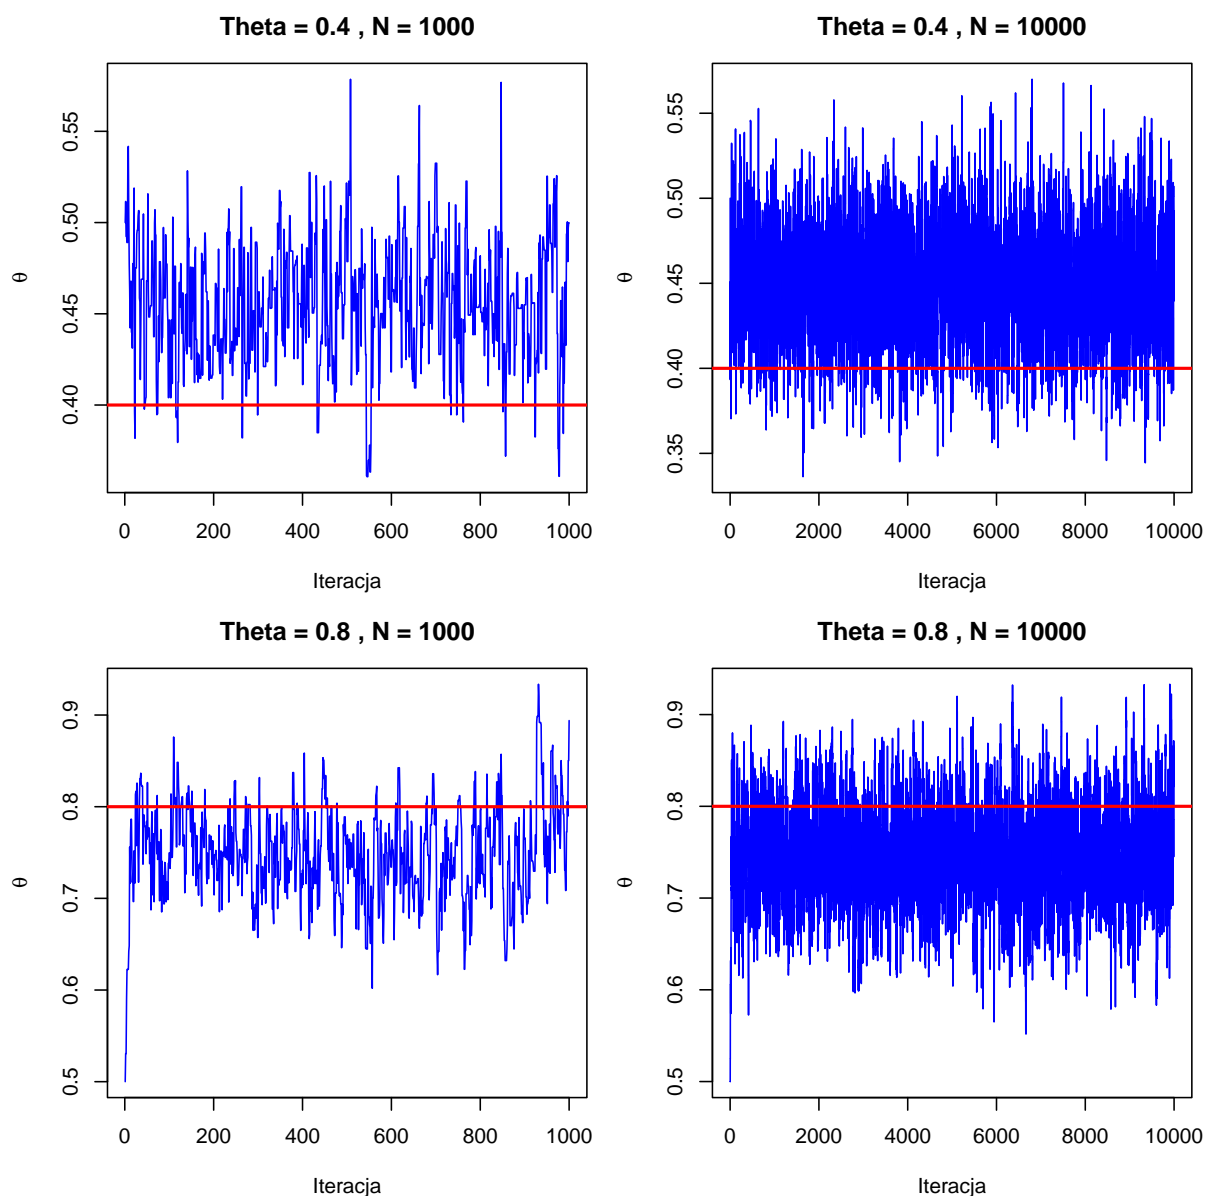
estimates <- rbind(estimates, data.frame(
  Prawdziwa_Theta = th_true,
  Dlugosc_Lancucha = L,
  Est_Srednia = mean(ch_clean),
  Est_Mediana = median(ch_clean)
))
}
}

```

Tabela 5: Estymacja parametru ϑ metodą MCMC dla dwóch przypadków

| Prawdziwa_Theta | Dlugosc_Lancucha | Est_Srednia | Est_Mediana |
|-----------------|------------------|-------------|-------------|
| 0.4 | 1e+03 | 0.4546 | 0.4535 |
| 0.4 | 1e+04 | 0.4491 | 0.4487 |
| 0.4 | 1e+05 | 0.4490 | 0.4486 |
| 0.8 | 1e+03 | 0.7489 | 0.7473 |
| 0.8 | 1e+04 | 0.7451 | 0.7439 |
| 0.8 | 1e+05 | 0.7437 | 0.7429 |

Poniżej przedstawiono przebiegi łańcuchów (Trace plots) dla obu badanych parametrów ϑ oraz długości $N = 1000$ i $N = 10000$.



Rysunek 1: Przebieg łańcuchów Markowa (Trace plots) dla $\vartheta = 0.4$ (góra) i $\vartheta = 0.8$ (dół).

Wnioski: Analiza wykresów śladowych (trace plots) wskazuje na poprawną zbieżność algorytmu Metropolis-Hastingsa. Łańcuchy dla obu wartości (0.4 oraz 0.8) szybko osiągają stacjonarność. Obserwowane przesunięcie średniej wartości łańcucha (niebieski wykres) względem prawdziwej wartości parametru (czerwona linia) jest zjawiskiem naturalnym i wynika z losowości generowania próby danych ($n = 100$).

3 Przedział wiarogodny najwyższej gęstości (HPD)

Wyznaczamy 95% przedział HPD dla parametru ϑ z Zadania 2. Do analizy wybrano przypadek, gdzie prawdziwe $\vartheta = 0.4$ (najdłuższy wygenerowany łańcuch).

```
calc_HPD <- function(chain, alpha=0.05) {
  M <- length(chain)
  burn_in <- floor(M/10)
```

```

chain_clean <- sort(chain[-(1:burn_in)])
Mu <- length(chain_clean)

k <- floor((1 - alpha) * Mu)
idx_start <- 1:(Mu - k)
idx_end <- idx_start + k

diffs <- chain_clean[idx_end] - chain_clean[idx_start]
best_idx <- which.min(diffs)

lower <- chain_clean[best_idx]
upper <- chain_clean[best_idx + k]


return(c(Lower=lower, Upper=upper, Length=diffs[best_idx]))
}

# Używamy zapamiętanego łańcucha z Zadania 2 (dla theta = 0.4)
hpd_res <- calc_HPD(longest_chain_task3, alpha=0.05)

# Dane do wykresu
burn_in_plot <- floor(length(longest_chain_task3) * 0.1)
chain_for_hist <- longest_chain_task3[-(1:burn_in_plot)]

```

Otrzymany 95% przedział HPD: [0.3835, 0.5191].



Rysunek 2: Rozkład a posteriori dla $\vartheta = 0.4$ z zaznaczonym przedziałem HPD.

Wnioski: Można zauważyć, że maksimum funkcji gęstości a posteriori (moda) jest nieco przesunięte względem prawdziwej wartości parametru (0.4). Jest to bezpośrednia konsekwencja zjawiska opisanego w zadaniu drugim, algorytm wyznaczył rozkład a posteriori na podstawie konkretnej, wylosowanej 100-elementowej próby, która mogła losowo faworyzować nieco wyższe wartości parametru. Mimo to, przedział HPD zawiera prawdziwą wartość.